

ENGENHARIA DE DADOS · AV1 · PARTE 1

Data Lake de corridas urbanas 100% em Terraform

Quais bairros de Recife concentram mais receita na madrugada?

Grupo 11 · CESAR School · 2026.2

Thiago von Sohsten · Felipe Sérgio · Sérgio Gouveia · Thiago Menezes · Matheus Lucena · Lui Manso · Rodrigo Souza

Corridas urbanas em Recife

- Evento: **corrida finalizada**
- Pergunta: **quais bairros** concentram maior receita na **madrugada** (00h–05h)?
- Sujeira plausível: **valor** chega com vírgula decimal em parte dos eventos

518.400

eventos · 30 dias × 12 por minuto


117,6 MB

117.584.519 bytes em JSON Lines

1,48%

7.688 eventos com vírgula decimal
em `valor`

O que o Terraform sobe



Terraform · módulo `modules/lake` · backend remoto **S3 + DynamoDB** · workspace `av1` · região `us-east-1`

- Schema **declarado no IaC** — sem Crawler
- Tags em tudo: `turma=eda262` · `grupo=g11` · `projeto=engenharia-de-dados`

Cada decisão, com um número

DECISÃO	ESCOLHA	NÚMERO MEDIDO
Grão	Uma linha por corrida finalizada	518.400 linhas
Chave	<code>corrida_id</code> (sequencial, único)	518.400 distintos
Formato	<code>valor</code> como <code>double</code> ; custo: vírgula vira <code>null</code>	7.688 nulls · 1,48%
Partição	Nenhuma (fora do escopo da AV1)	varre 117.587.268 B
Custo	Teto por consulta no workgroup	268.435.456 B (256 MiB)

O teto fica acima do volume medido: a pergunta passa, e uma consulta acidental muito maior é barrada.

apply → consulta → custo → destroy

1 · apply

conta limpa, workspace av1

2 · dados

upload para o S3

3 · Athena

pergunta de negócio

4 · destroy

sem órfãos

```
SELECT bairro,
       count(*)           AS corridas_madrugada,
       round(sum(valor), 2) AS receita_madrugada
FROM   corridas_trusted
WHERE  substr(data_corrida, 12, 2) BETWEEN '00' AND '05'
       AND valor IS NOT NULL
GROUP BY bairro
ORDER BY receita_madrugada DESC
LIMIT 5;
```

Verificação automática: `verificacao/verifica.sh` imprime PASSA/FALHA por critério e `--pos-destroy` confere que nada sobrou.

Quanto custou responder a pergunta

117.587.268

DataScannedInBytes
(consulta no Athena)

US\$

0,00053472

custo = bytes ÷ 1 TiB × US\$ 5

43,8%

do teto de 256 MiB utilizado

- Resposta: **Boa Viagem** lidera a madrugada — 8.564 corridas, **R\$ 138.210**
- Sem partição, a consulta lê tudo — **aceito na AV1**, otimizado só na Parte 2

QueryExecutionId: 34753c1e-c6cc-46a6-8790-a14567e37774

O que entregamos

- Data Lake **do zero em Terraform**, com módulo, backend remoto e workspace
- Pergunta respondida no Athena com **custo por consulta medido**
- Decisões com número em `DECISOES.md`
- `destroy` limpo, conferido por `verifica.sh`

Próximo (Parte 2): Parquet particionado, três camadas e ingestão idempotente.