

ENGENHARIA DE DADOS · AV1 · PARTE 1

Data Lake de corridas urbanas 100% em Terraform

Quais bairros de Recife concentram mais receita na madrugada?

Grupo 11 · CESAR School · 2026.2

Thiago von Sohsten · Felipe Sérgio · Sérgio Gouveia · Thiago Menezes · Matheus Lucena · Lui Manso · Rodrigo Souza

Corridas urbanas em Recife

Evento: **corrida finalizada**

Pergunta: **quais bairros** concentram maior receita na **madrugada** (00h–05h)?

Sujeira plausível: **valor** chega com vírgula decimal em parte dos eventos

518.400

eventos · 30 dias × 12 por minuto


117,6 MB

117.584.519 bytes (112,1 MiB) em
JSON Lines

1,48%

7.688 eventos com vírgula decimal
em valor

O que o Terraform sobe



Terraform · módulo `modules/lake` · backend remoto **S3 + DynamoDB** · workspace `av1` · região `us-east-1`

Schema **declarado no IaC** — sem Crawler

Tags em tudo: `turma=eda262` · `grupo=g11` · `projeto=engenharia-de-dados`

Cada decisão, com um número

DECISÃO	ESCOLHA	NÚMERO MEDIDO
Grão	Uma linha por corrida finalizada	518.400 linhas
Chave	corrida_id (sequencial, único)	518.400 distintos
Formato	valor como double ; custo: vírgula vira null	7.688 nulls · 1,48%
Partição	Nenhuma (fora do escopo da AV1)	varre 117.587.268 B
Custo	Teto por consulta no workgroup	268.435.456 B (256 MiB)

O teto fica acima do volume medido: a pergunta passa, e uma consulta acidental muito maior é barrada.

Medido no Athena: sem `use.null.for.invalid.data` a consulta falhou (`BAD_DATA` , valor 13,61). Com a propriedade no Terraform: `count(valor) = 510.712`, ou seja, **7.688 nulls**.

apply → consulta → custo → destroy

1 · apply

9 recursos criados · workspace av1

2 · dados

518.400 eventos no S3 · 112,1 MiB

3 · Athena

Boa Viagem · Pina · Recife Antigo

4 · destroy

9 destruídos · 15/15 · 0 órfãos

```
SELECT bairro,
       count(*)           AS corridas_madrugada,
       round(sum(valor), 2) AS receita_madrugada
FROM   corridas_trusted
WHERE  substr(data_corrida, 12, 2) BETWEEN '00' AND '05'
       AND valor IS NOT NULL
GROUP BY bairro
ORDER BY receita_madrugada DESC
LIMIT 5;
```

Evidência: `verifica.sh` deu **6 PASSA · 0 FALHA** (60/60) com a stack no ar; `--pos-destroy` deu **15/15**, nenhum órfão. Arquivos em `evidencias/` .

Quanto custou responder a pergunta

117.587.268

DataScannedInBytes
(consulta no Athena)

US\$

0,00053472

custo = bytes ÷ 1 TiB × US\$ 5

43,8%

do teto de 256 MiB utilizado

Resposta: **Boa Viagem** lidera a madrugada — 8.564 corridas, **R\$ 138.210**

Sem partição, a consulta lê tudo — **aceito na AV1**, otimizado só na Parte 2

QueryExecutionId: 34753c1e-c6cc-46a6-8790-a14567e37774

O que entregamos

Data Lake **do zero em Terraform**, com módulo, backend remoto e workspace

Pergunta respondida no Athena com **custo por consulta medido**

Decisões com número em `DECISOES.md`

`destroy` limpo, conferido por `verifica.sh`

Próximo (Parte 2): Parquet particionado, três camadas e ingestão idempotente.